

SNT

**Interdisciplinary
Centre for Security,
Reliability and Trust**


1. Contexte
2. Qu'est ce que la mémorisation de données ?
3. Exploitation du phénomène
4. Challenges
5. Précautions
6. Conclusion




SNT

Contexte


Cas 1



Cas 1



Cas 2



SNT

Mémorisation des données



Mémorisation des données

La mémorisation des données est définie comme le manque de généralisation d'un modèle qui tend à se souvenir et à rappeler les détails des données sur lesquelles il a été formé.



Verbatisme

Désigne la mémorisation et la restitution d'un texte ou d'un document au mot près.



Mémorisation des faits

Permet aux modèles de fournir des informations pertinentes des faits sur le monde et la culture générale.




Mémorisation des idées

Permet d'améliorer la capacité de raisonnement d'un modèle par la mémorisation des étapes à suivre pour atteindre un résultat.



Mémorisation du style d'écriture

Permet aux modèles de reproduire le style d'écriture d'une personne ou d'un format de document.



Conséquences



Contamination des données d'évaluation



Fuite des données personnelles




Problèmes de sécurité

SNT

Exploitation du phénomène

Attaque par inférence d'appartenance


L'objectif principal est de collecter des connaissances sur l'ensemble de données d'entraînement d'un modèle.



- Exploitation de la fonction de perte
- Etude de la distribution de probabilité des tokens
- Etude de la perplexité
- Etude de la similarité des réponses générées

Attaque par inférence d'appartenance

Il sert de pierre angulaire pour des attaques plus complexes.





Détection d'hallucination

Les hallucinations sont souvent définies comme des LLM générant « un contenu qui n'a pas de sens ou qui n'est pas fidèle au contenu source fourni ».

SNT

Challenges



Challenges



Les attaques par inference d'appartenance n'ont pas de performance si élevée.



Floue entre le phénomène de mémorisation et celui d'interpolation.



Politiques en matière d'identification et de protection de donnée sensibles / privées.

SNT

Précautions



Coté déveléppement

- Deduplication des données
- Dé-identification des données à caractère personnel
- Filtre de mémorisation
- Pré-traitement des instructions



Coté utilisateurs



Soyez prudent avec les données que vous soumettez !



SNT

Conclusion

Conclusion

- Impact de la mémorisation des données
- Prudence avec la soumission des données



Références

- Luo, Yun, et al. "An empirical study of catastrophic forgetting in large language models during continual fine-tuning." *arXiv preprint arXiv:2308.08747* (2023).
- Speicher, Till, et al. "Understanding Memorisation in LLMs: Dynamics, Influencing Factors, and Implications." *arXiv preprint arXiv:2407.19262* (2024).
- Hartmann, Valentin, et al. "Sok: Memorization in general-purpose large language models." *arXiv preprint arXiv:2310.18362* (2023)
- Ozdayi, Mustafa Safa, et al. "Controlling the extraction of memorized data from large language models via prompt-tuning." *arXiv preprint arXiv:2305.11759* (2023).
- Lukas, Nils, et al. "Analyzing leakage of personally identifiable information in language models." *2023 IEEE Symposium on Security and Privacy (SP)*. IEEE, 2023.



Interdisciplinary Centre for Security, Reliability and Trust

Contact: eurasted@gmail.com